ИТМО

Перспективные методы ИИ

Натыкин Максим Викторович

Технологии искусственного интеллекта в урбанистике

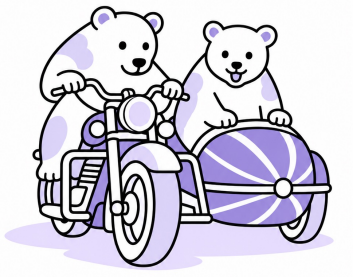
Слабый и сильный ИИ

ИТМО

Слабый ИИ

Интеллект «братьев меньших»

1) Компьютерное зрение
2) Обработка естественного языка
3) Анализ и синтез речи
4) Беспилотный транспорт





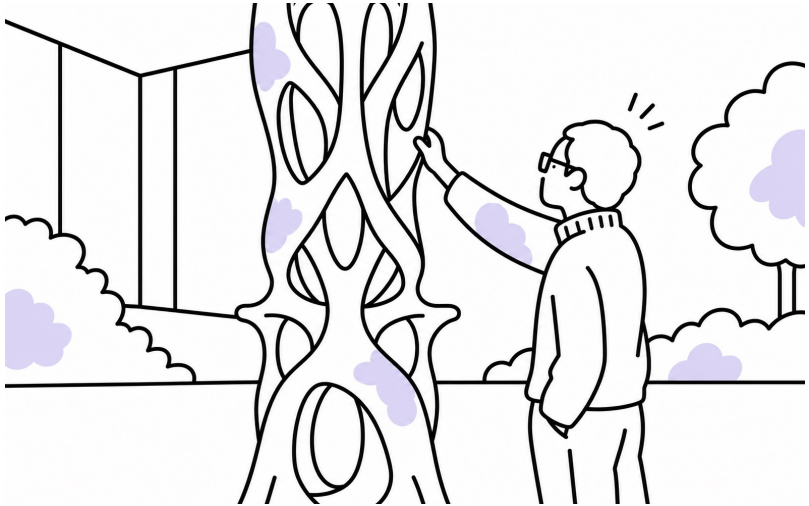
Сильный ИИ



Сильный ИИ – тип ИИ, который может решать различные задачи, взаимодействовать с человеком и самостоятельно обучаться

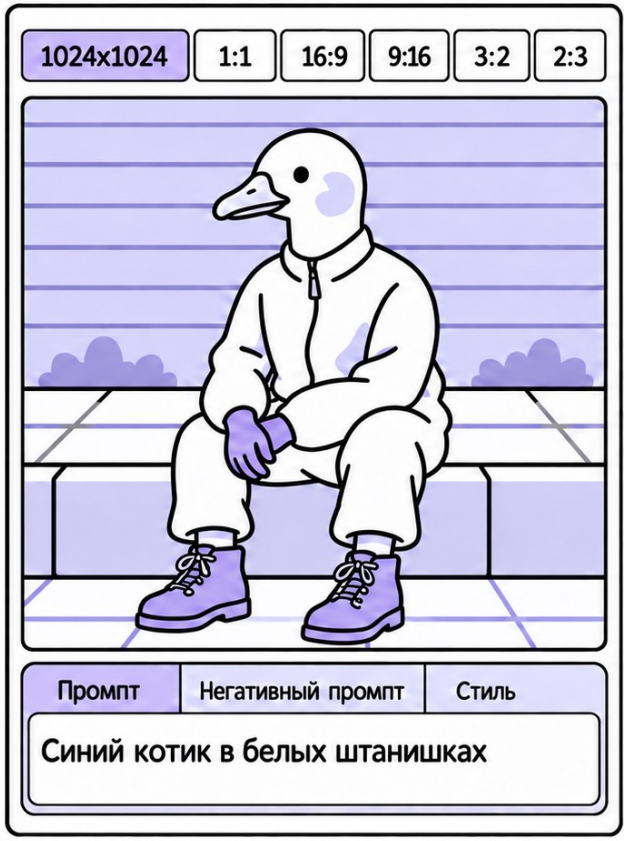
Что такое перспективные методы ИИ

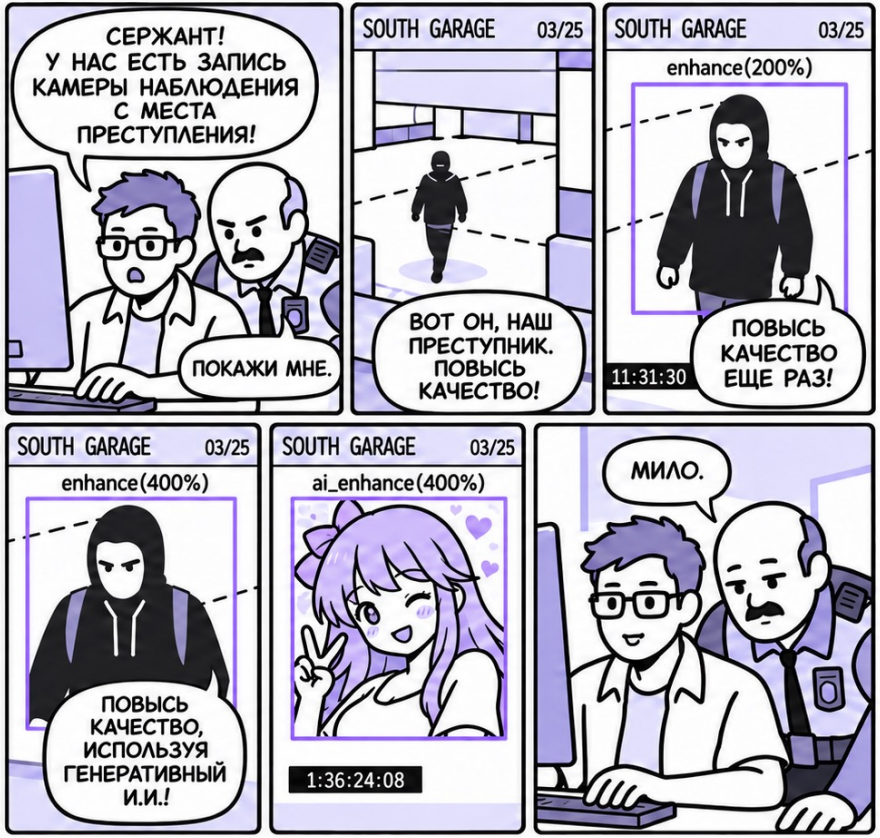
Перспективные методы искусственного интеллекта – методы, направленные на создание принципиально новой научно-технической продукции, в том числе в целях разработки универсального (сильного) искусственного интеллекта (автономное решение различных задач, автоматический дизайн физических объектов, автоматическое машинное обучение, алгоритмы решения задач на основе данных с частичной разметкой и (или) незначительных объемов данных, обработка информации на основе новых типов вычислительных систем, интерпретируемая обработка данных и др.)



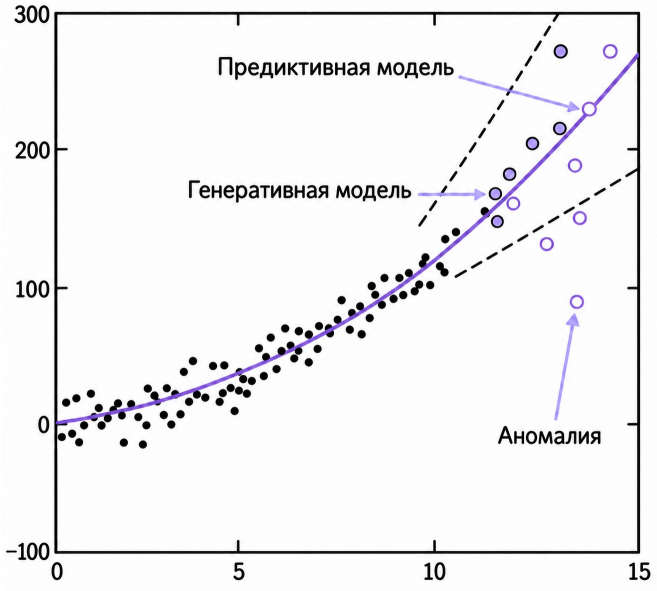
Указ Президента Российской Федерации от 10.10.2019 г. № 490. О развитии искусственного интеллекта в Российской Федерации, п. 5(в)

Генеративный ИИ и доверие галлюцинациям



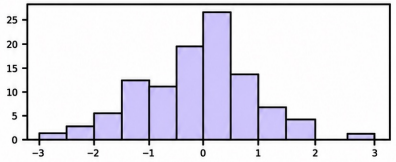


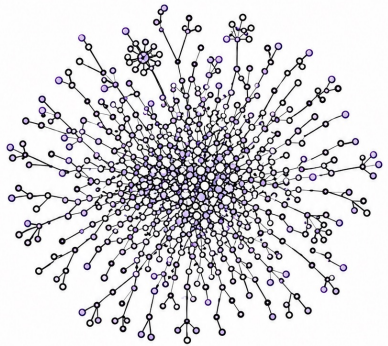
Генеративный ИИ - дальний родственник... Монте-Карло



Генеративный ИИ создает новые непротиворечивые объекты в условиях неопределенности
(имитируя интеллект человека)

- Классические методы Монте-Карло генерации выборок для случайных событий, величин и функций.
- Методы Монте-Карло для композитных объектов (комплексные сети и пр.)
- Генеративные модели на основе нейросетей (генератор против дискриминатора)



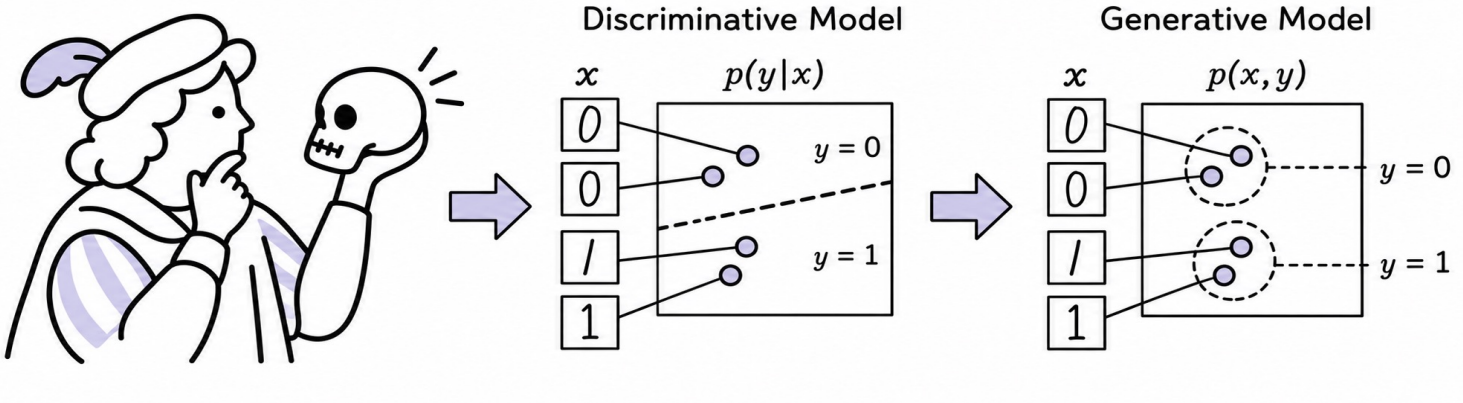




Генеративные модели и многомерные распределения

Генеративная модель пытается генерировать рукописные 0 и 1, для этого моделирует распределение по всему пространству данных.

Дискриминативная модель старается разделить данные, без необходимости точно моделировать, как объекты размещаются по обе стороны от линии.



Ng A., Jordan M. On discriminative vs. generative classifiers: A comparison of logistic regression and naive bayes //Advances in neural information processing systems. – 2001. – Vol. 14.

https://developers.google.com/machine-learning/gan/generative

Имитация креативности – генеративный ИИ

ИТМО

Chat GPT

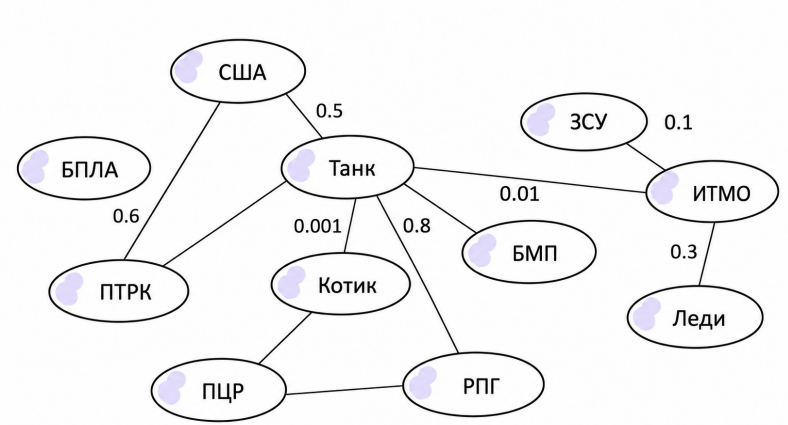
D

Вот шутка:
-Когда грибочек пьет валерьянку?
-Когда он волнушка.

Сделай мне 5 таких же милых и похожих на эту.

1. Когда мышонок ест огурчик?
   -Когда он огуречик.
2. Когда котенок пьет молоко?
   -Когда он молоченок.
3. Когда медвежонок играет в волейбол?
   -Когда он медвежатбол.
4. Когда зайчик кушает овощи?
   -Когда он зайчевочик.
5. Когда муравей смотрит телевизор?
   -Когда он муравьебай.

Большая языковая модель (Large Language Model): всевозможные сочетания всех слов и фраз



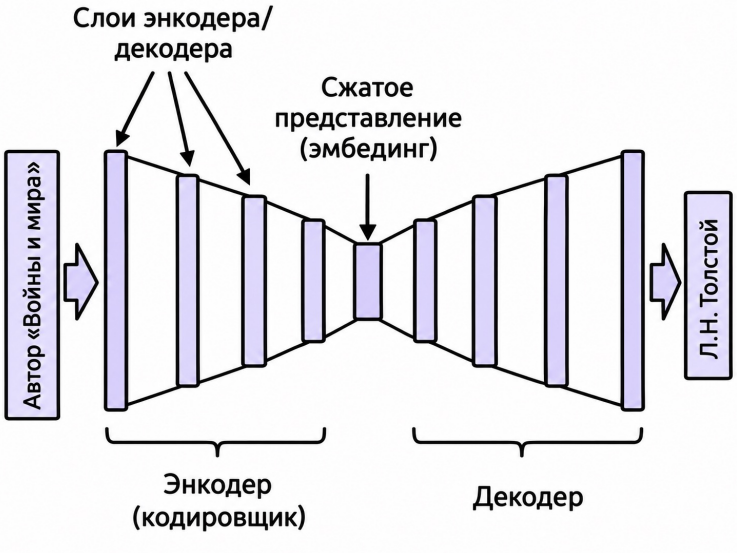
Танк США обнаружен с **БПЛА и подбит** ПТРК

Котик на танке приехал в **ИТМО и стрелял из** РПГ

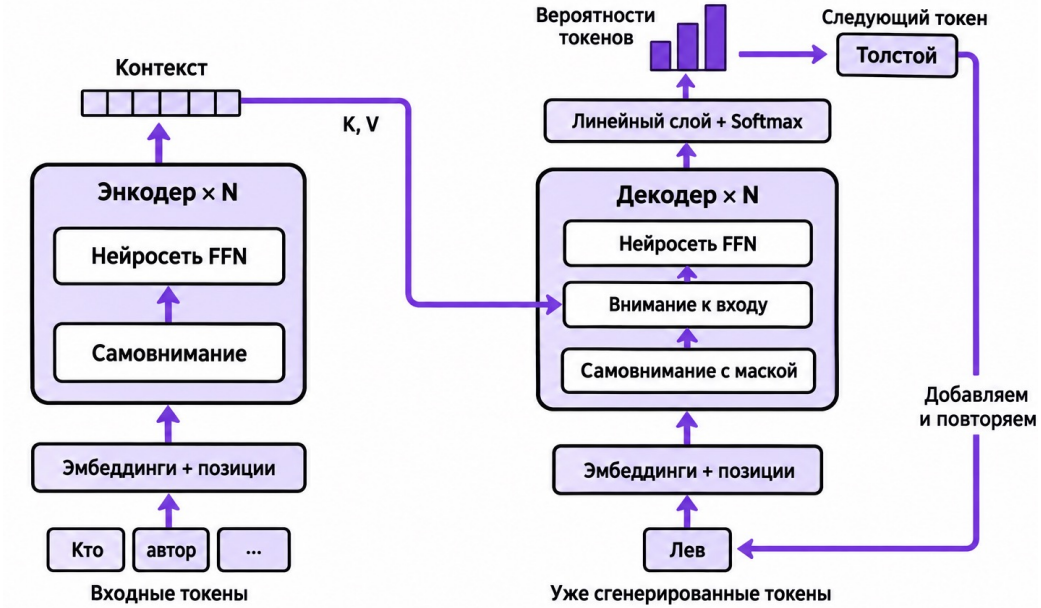
РПГ сдал ПЦР для поступления в ИТМО

Техническое устройство большой языковой модели

Простая схема энкодера-декодера, который лежит в основе трансформера большой языковой модели:



Чуть подробнее:

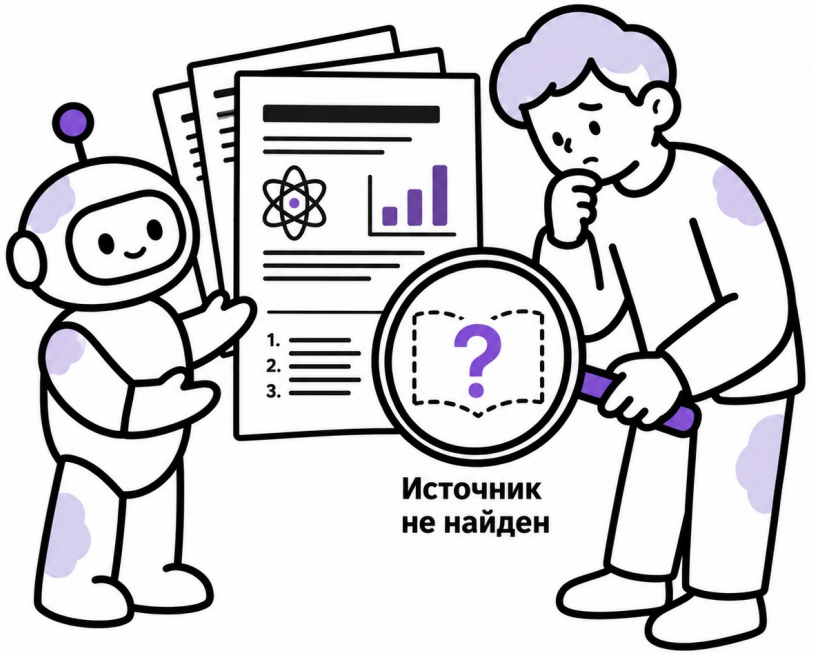


Миф №1: Скоро все обзоры будут написаны ИИ

ИТМО

ИИ относится к названиям статей не как к априорным фактам, а как к генерируемому тексту – и просто имитирует текст обзора

При этом наименования статей выглядят очень реалистично!



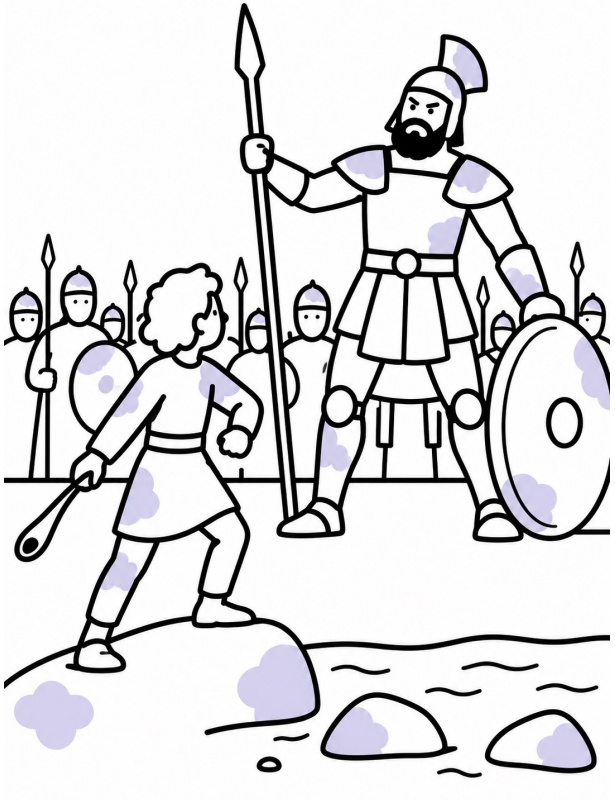
ИИ – не всегда поисковик нового поколения, а часто - талантливый имитатор фактов (т.н. галлюцинации больших языковых моделей)

Миф №2.1: ИИ запоминает системные факты из документов

ЯндексGPT

Кто такой Голиаф

Голиа́ф (ивр. גלית, греч. Голиа́θ) — герой, победитель турнира, устроенного царем древности Давидом (царём Иудеи).
Голиа́т (גליות) — согласно Библии (Книга Чисел) огромный филистимский воин, наводивший ужас на израильтян во время их завоевания земли Ханаанской.
Поединок Давида и Голиафа. Миниатюра из манускрипта «Bible historiée». Около 1320—1330 гг.



ИИ может вариативным образом интерпретировать соотношения между фактами и дать им свое изложение: для уменьшения вариативности нужно:

(а) больше данных и больше параметров модели

(б) директивно указать ИИ, что есть истина (в т.ч. RAG)

Миф №2.2: ИИ может сам себя «исправлять»

ИТМО

ЯндексGPT читает М.Ю. Лермонтова

Где мне купить книгу Лермонтова про купца Калашникова?

Книгу “Песня про царя Ивана Васильевича, молодого опричника и удалого купца Калашникова” Михаила Лермонтова можно купить во многих интернет-магазинах, например:

1. Лабиринте - https://www.labirint.ru/books/789837/
2. Озоне - https://www.ozon.ru/product/pesnya-pro-tsarya-ivana-vasilevicha-molodogo-oprichnika-i-udalogo-kuptsa-kalashnikova-199634671/
3. My-shop - https://my-shop.ru/shop/product/3904066.html

Вы также можете посетить книжные магазины вашего города или библиотеки, чтобы получить копию книги.

А чем занимался купец Калашников?

Купец Калашников был известным торговцем и производителем оружия в своем городе. Он занимался продажей различных видов оружия, таких как мечи, копья и стрелы, а также производством оружия для местного рынка.



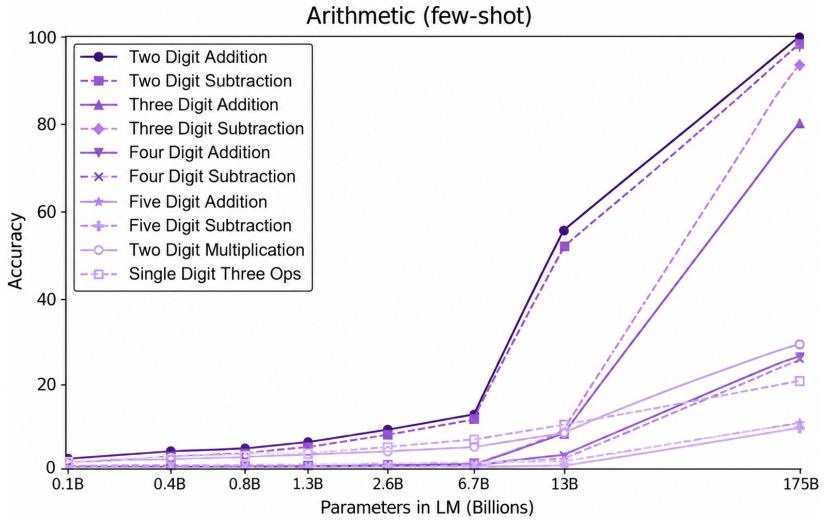
Купец Калашников не занимался оружием... он торговал тканями ☺

Нужны: технологии повышения качества моделей ИИ, ускорения обучения, снижения требований к вычислениям, адаптации к специфике отраслевых задач

Проблемы больших языковых моделей

ИТМО





Brown, Tom, et al. "Language models are few-shot learners." Advances in neural information processing systems 33 (2020): 1877-1901.

Девочки с тремя руками и винтовка со стволами вперед-назад: галлюцинации ИИ

Это может быть решено с помощью RAG

Автоматизация дообучения больших языковых моделей

ИТМО

Акела (Татнефть-ИТМО):

- Работа с разными предметными областями, в том числе через каскад моделей.
- Обогащение базы данных новыми документами.
- Автоматическая организация процесса дообучения.



Миф №3: LLM свободно владеют разными языками



Курьезы дообучения большой языковой модели (проблема перевода):

Если пришел на работу пьяным работник, что делать?

В случае **нарушения правил пьянки,** работники могут быть подвержены мерам административной и уголовной ответственности в соответствии с действующим законодательством, согласно п. 15.14 п.в.

Если LLM общается на одном языке, а «думает» на другом – проблемы неминуемы!

«Венец творения» – LLM-агенты и AGI

ИИ-агенты (Reason + Act) – парадигма в искусственном интеллекте, которая объединяет логическое рассуждение (Reasoning) и выполнение действий (Acting).



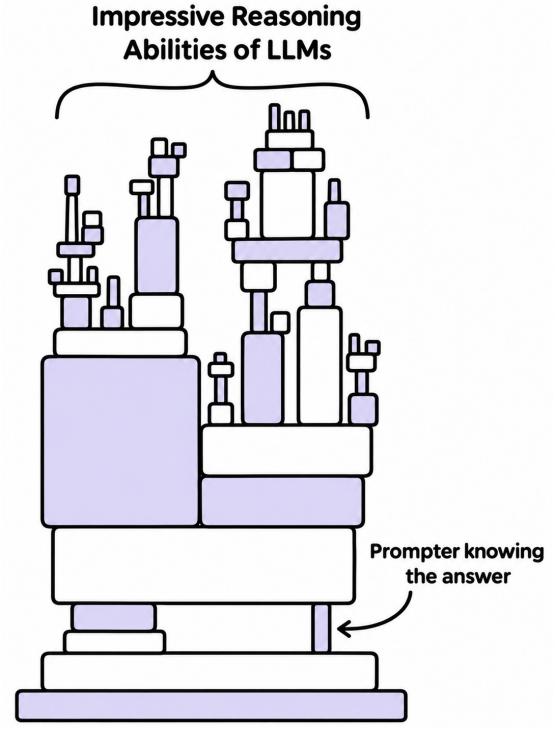
«Венец творения» – LLM-агенты и AGI

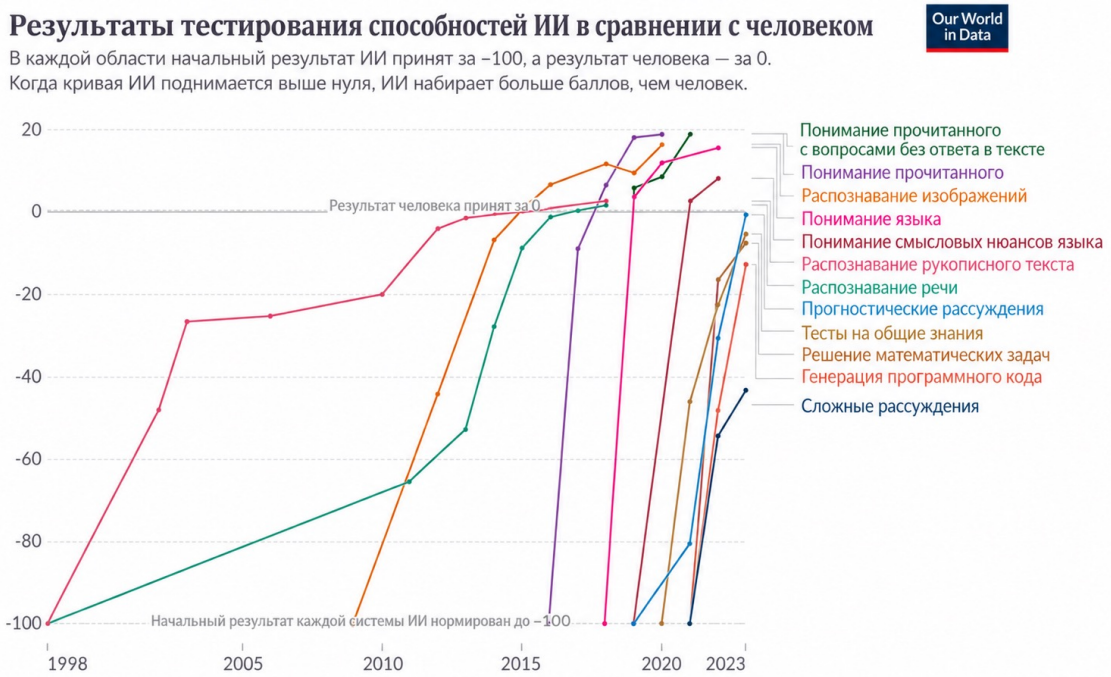
Пример: WarAgent – мультиагентная система с поддержкой LLM для моделирования решений стран и последствий в исторических международных конфликтах. Или форум ИИ агентов.





Что нас ждет в ближайшем будущем

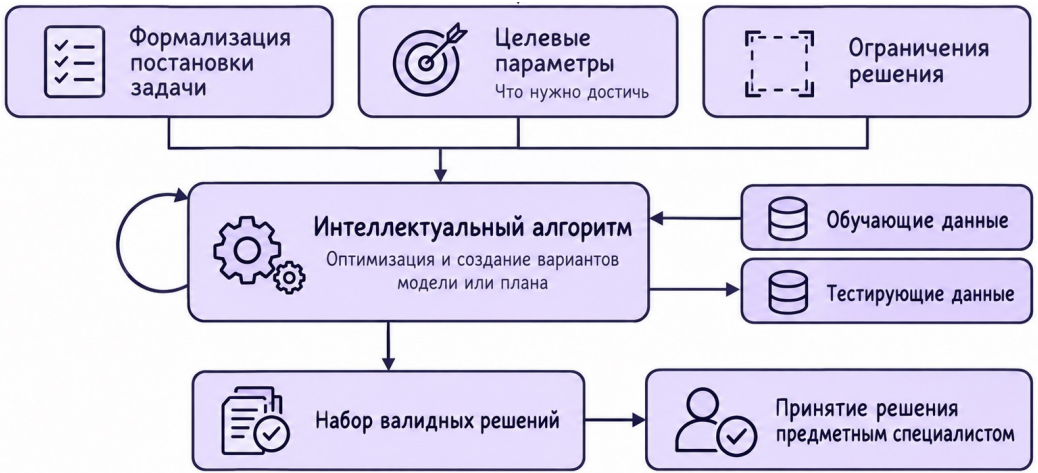




ИИ на основе LLM в итоге будет конкурировать с человеком почти во всех профессиях. Готовы ли мы оценивать результаты его деятельности?

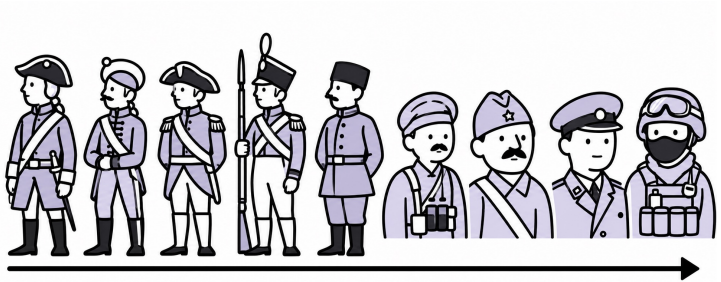
Автоматическое машинное обучение (AutoML)

Формулировка проблемы от предметных специалистов



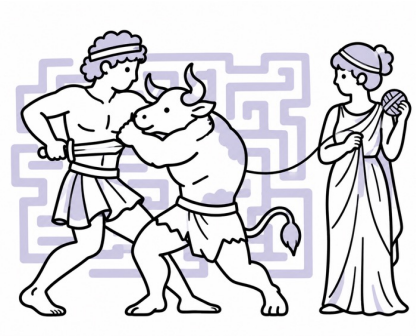
ИИ сам создает модели на данных за человека на основе сгенерированных вариантов

Эволюционный выбор решения таким образом, что чтобы из всех возможных вариантов найти наилучший по заданному критерию



Направление эволюции задается набором метрик качества, которые надо достичь

Генеративный подход к AutoML – эволюция моделей



Про Тесея, Ариадну и минотавра: каждый успешный пайплайн машинного обучения – это эффективный путь в графе знаний машинного обучения... который мы полностью не знаем – и никогда не узнаем

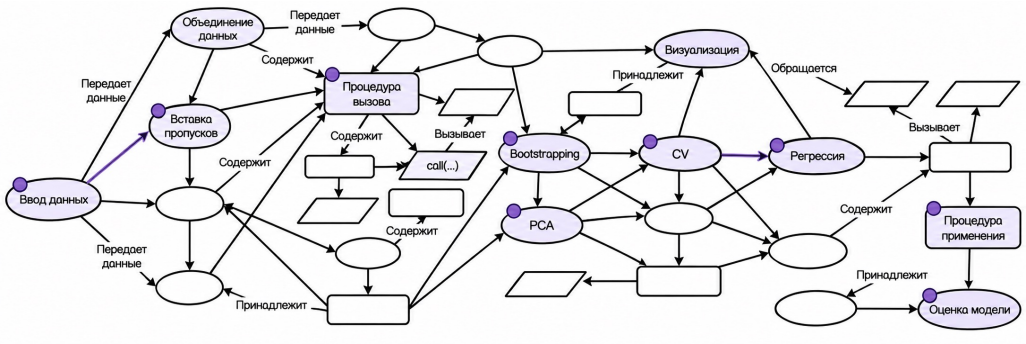
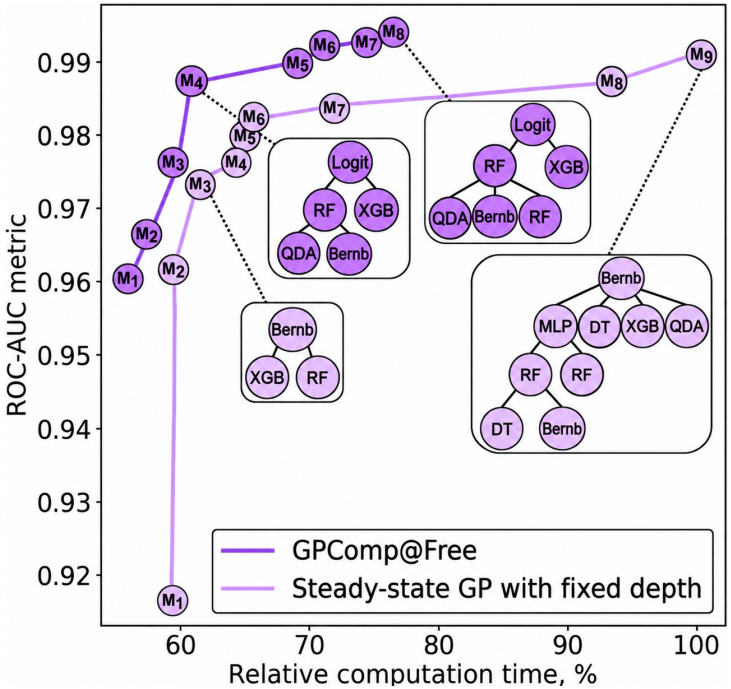
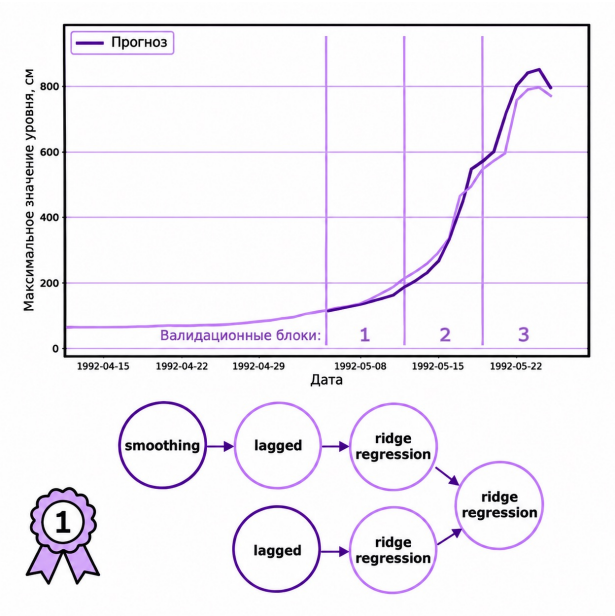


Диаграмма качества эволюции моделей

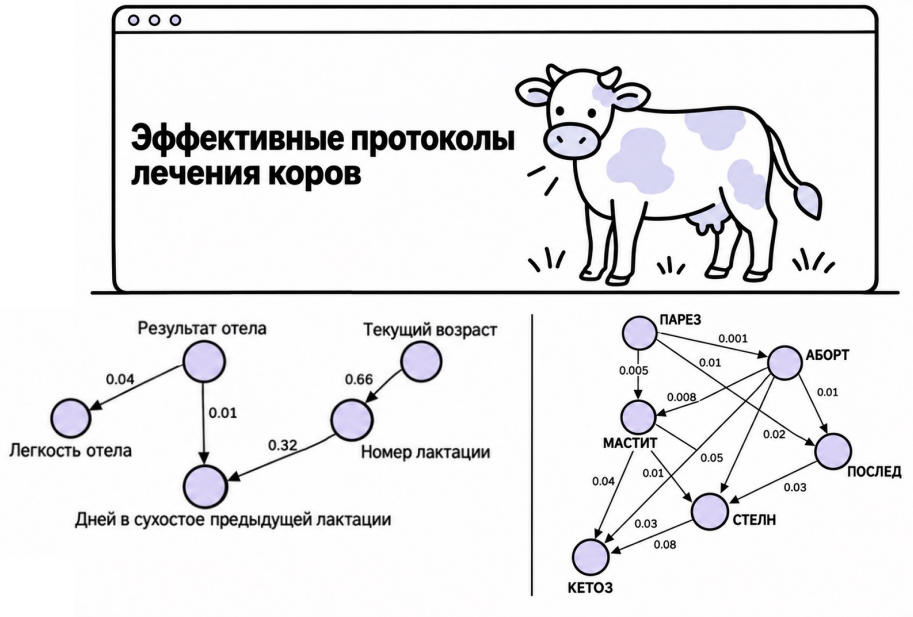


Результат работы генетического алгоритма – пайплайн модели на данных

Миф №4: модель, сделанная человеком, всегда лучше, чем ИИ



Хакатон МЧС: прогнозирование наводнений на р. Лена



Хакатон Россельхозбанка: предсказание закономерностей в заболеваниях коров

FEDOT

AutoML рулит быстрее, чем человек!

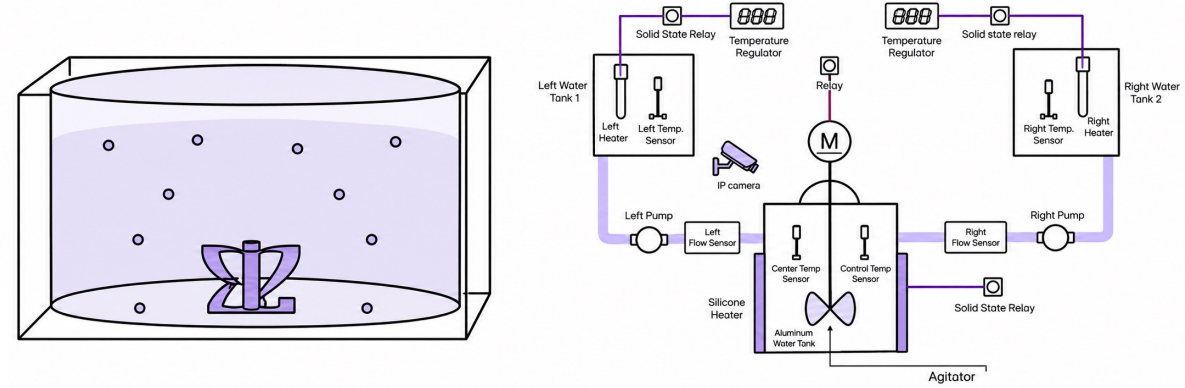
BAUT

Практическая польза от AutoML: опыт ИТМО

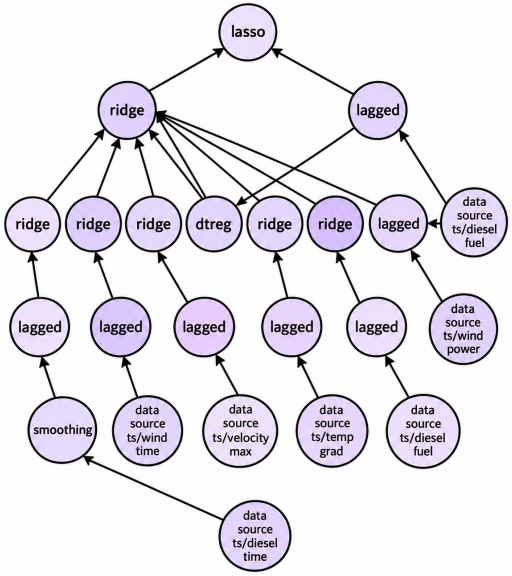
ИТМО

FEDOT – технология создания композитных моделей на данных посредством автоматического машинного обучения

- Применение эволюционных алгоритмов и методов регуляризации для поиска оптимальной структуры модели на данных.
- Работа с мультимодальными данными (табличные данные, изображения, текст).
- Эффективное использование распределенных инфраструктур
- Использование открытых библиотек машинного обучения, интеграция с предметными моделями.
- Реализация в форме открытого фреймворка на языке Python.



Пример 1: Установка для создания модели химического реактора



Пример 2: Структура модели электрогенератора на основе композиции стандартных моделей ML

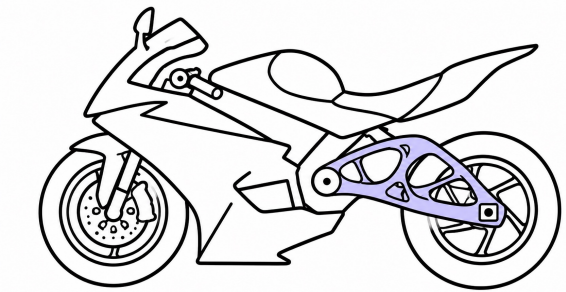
Ускорение разработки и настройки моделей – до 20 раз

Генеративный дизайн объектов реального мира

ИТМО

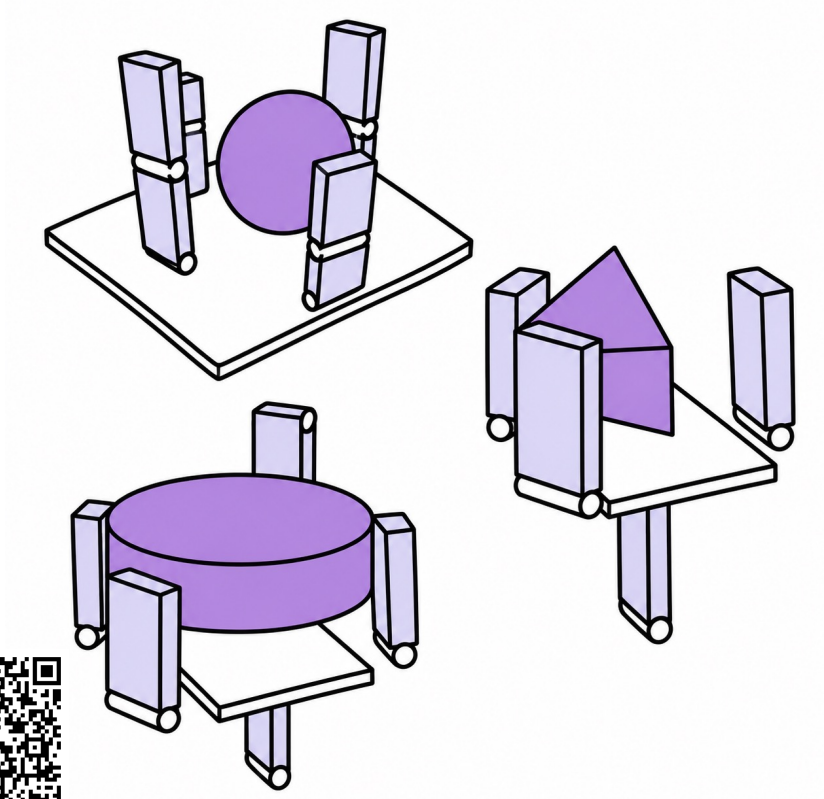
Генеративный дизайн – оптимизация структуры и характеристик объектов техники и технологий в условиях неопределенности и с «открытыми» ограничениями с помощью ИИ

1) **Неопределенность** в формулировках целевой функции и ограничений.
2) **Вычислительная и физическая ничтожность** синтетических структур.
3) Динамика воспроизводимой системы (**объективное отсутствие доказательства сходимости** алгоритма).
4) Отсутствие объективных **критериев качества (не всегда целевая функции и ограничения в явном виде).**
5) **«Нежданчики»:** эффекты сложности (complexity) – появление новых свойств системы, не следующих из генеративной логики.

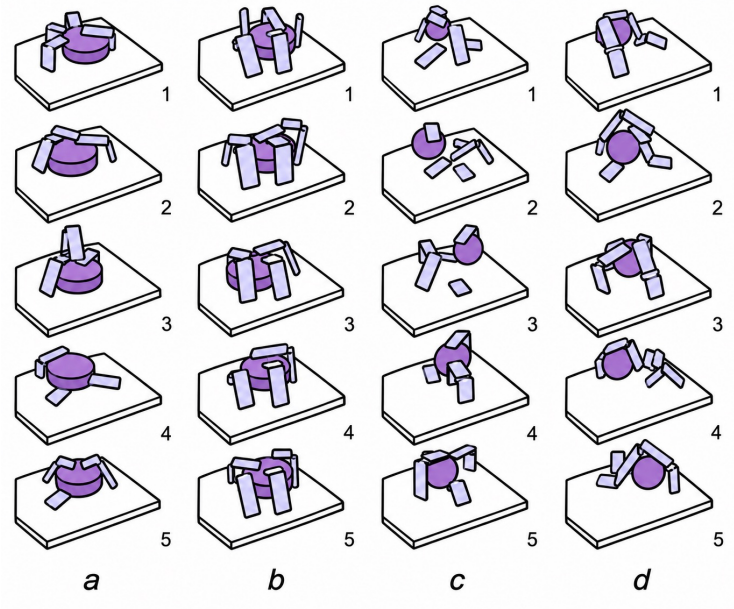


Генеративный дизайн – это не структурная оптимизация!

ИТМО



ROSTOK – технология генеративного дизайна подвижных элементов робототехнических систем в динамике от ИТМО.



Генеративный дизайн парков: зонирование

ИТМО

Обучение алгоритма ИИ на базе успешных архитектурно-ландшафтных проектов



Генеративный дизайн парков: инфраструктура

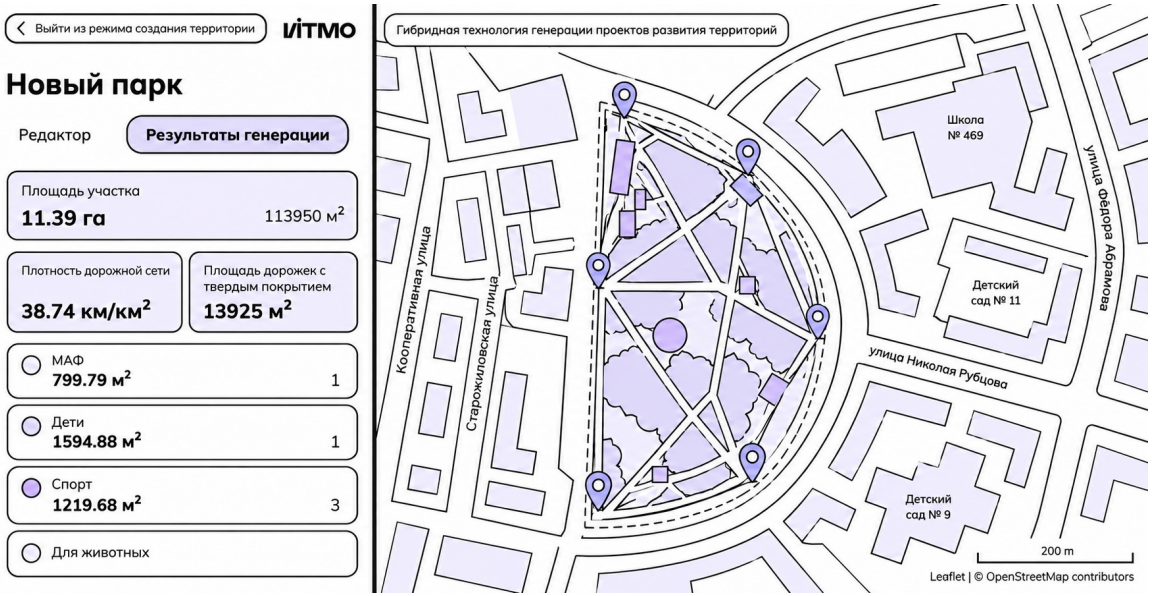
ИТМО

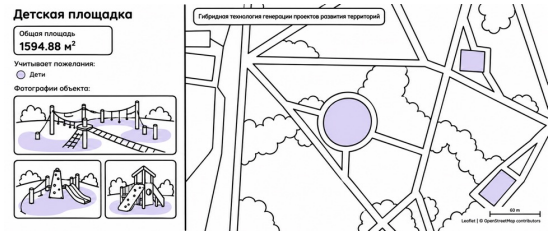
Назначение:

- Планирование городских парков и общественных пространств.

Результаты:

- Планирование территорий под озеленение и благоустройство.
- Функциональный состав сервисов и инфр-ры в рекреационных зонах.
- Учет потребностей горожан исходя из масштабов рекреационных зон.
- Подбор оптимального породного состава зеленых насаждений.





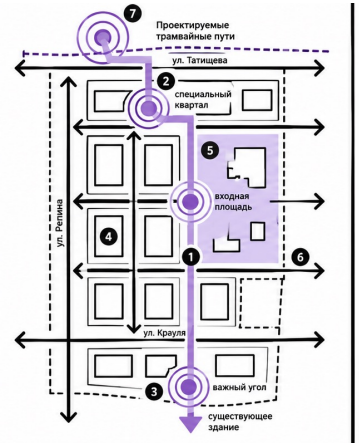
улица Валерия Гаврилина

Миф №5: Тупой ИИ не понимает художественный замысел

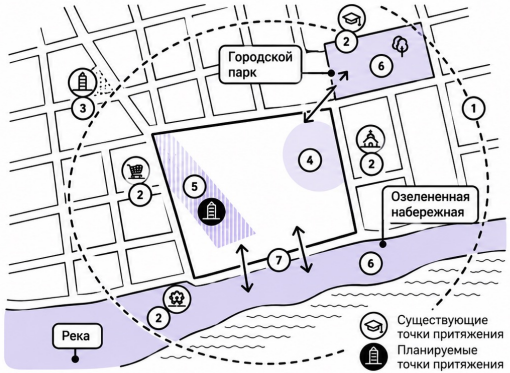
Автогенерация проектов на базе архитектурных замыслов

Результаты:

- ❑ Автоматический анализ архитектурных концепций на предмет системных архитектурных и планировочных решений.
- ❑ Создание проектов не (только) по нормам, а с градостроительными смыслами.
- ❑ Учёт окружающего городского контекста.





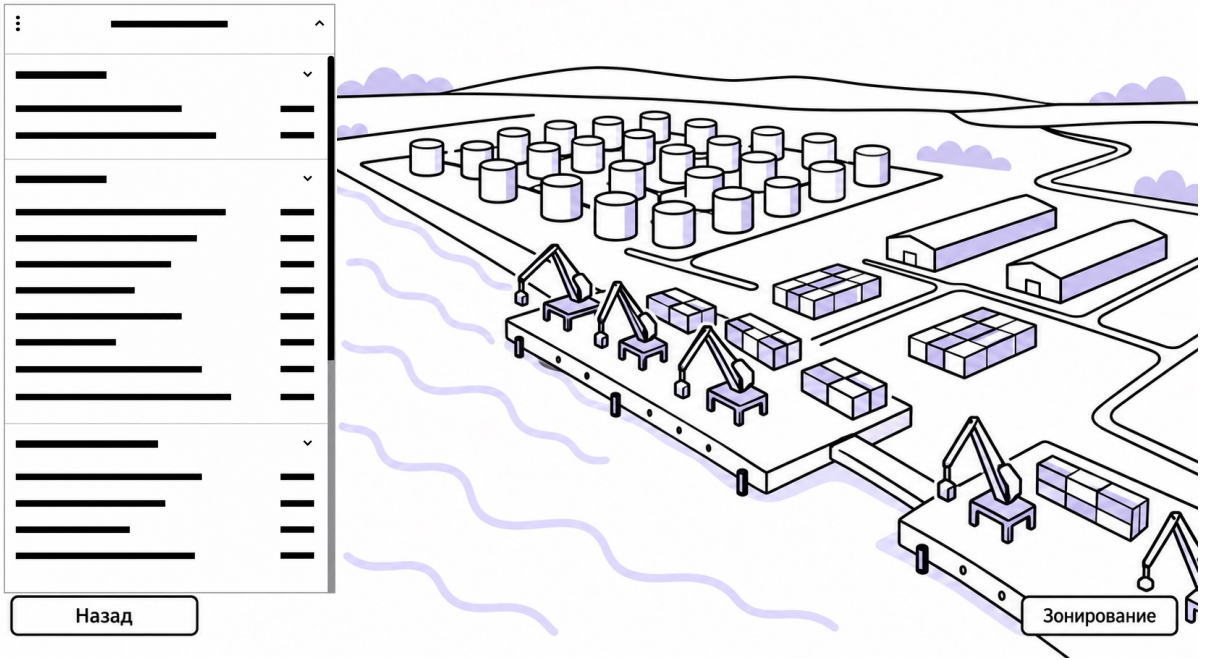




Генеративный дизайн промышленной застройки

Технология GEFEST – генеративный дизайн изделий и объектов в сплошных средах

- Построение системы объектов с оптимальной геометрией.
- Управление границей поиска оптимальных решений.
- Подключение внешних моделей динамики сплошной среды.
- Ускорение за счет суррогатных моделей, учет множественных критериев.



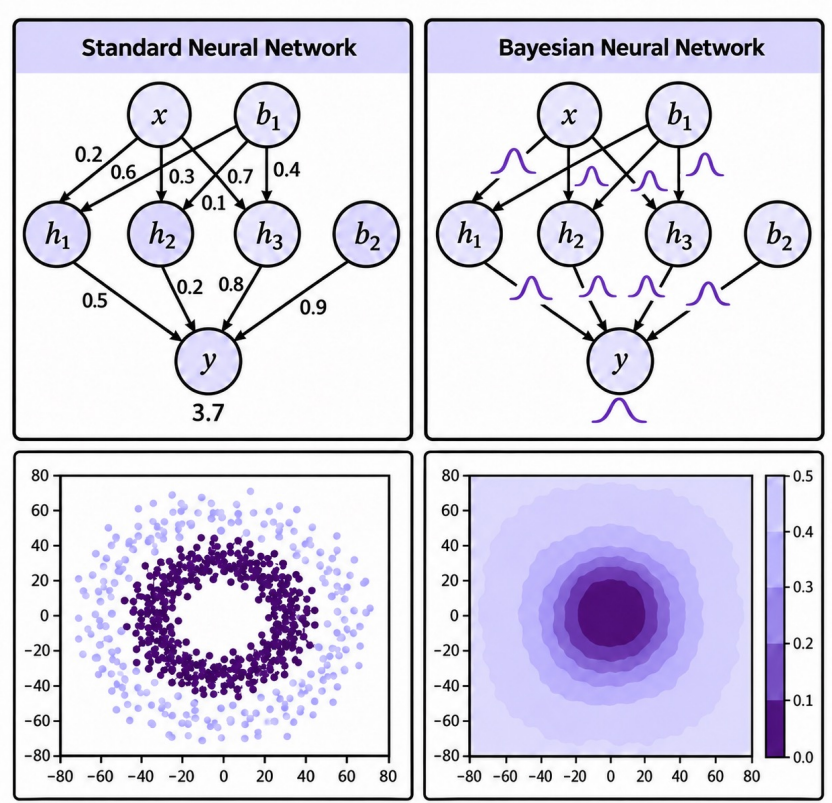
Пример: концептуальный дизайн промышленно-логистической инфраструктуры в Арктической зоне (порт в Обской губе) с учетом экстремальных температурных, ветро-волновых и ледовых воздействий.

Интерпретируемость и доверие к технологиям ИИ

ИИ, который объясняет другой ИИ

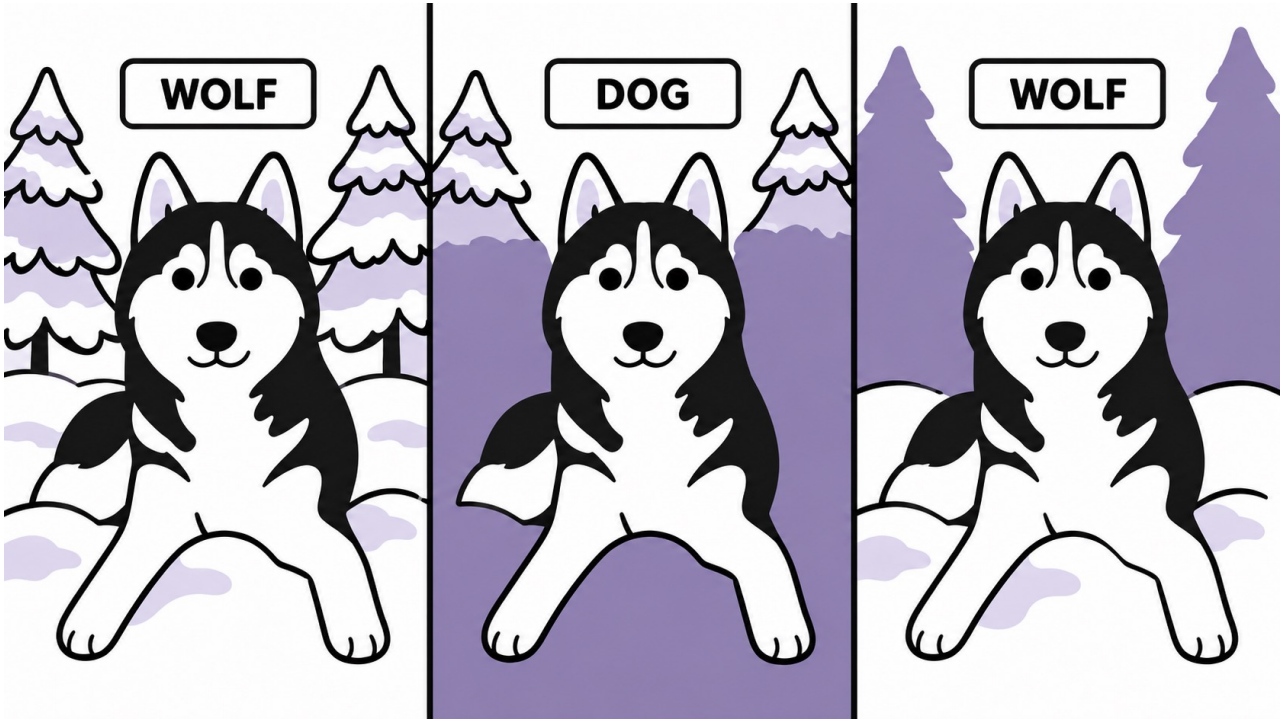
- Глобальная объяснимость (решающие деревья, суррогатные модели)
- Локальная объяснимость (GradCAM, ScoreCAM, explanation by example)
- Байесовский и нейробайесовский подходы – позволяют строить модели, выходами которых является вероятностное распределение => оценка надежности предсказания.

Нейробайесовские модели получаются тогда, когда в нейросетевых моделях веса заменяются вероятностными распределениями весов.



Тепловая карта «уверенности» нейробайесовской модели

Тепловые карты: на что именно «смотрит» нейросеть?



Пример выявления некорректной работы нейросети с помощью XAI: модель считает снег ключевым признаком для класса “Волк”

Миф №6: Никто не знает, почему нейросеть решила так...

ИТМО

Сегментация изображений с БПЛА с целью выделения объектов капитального строительства (зданий) на фотографиях.

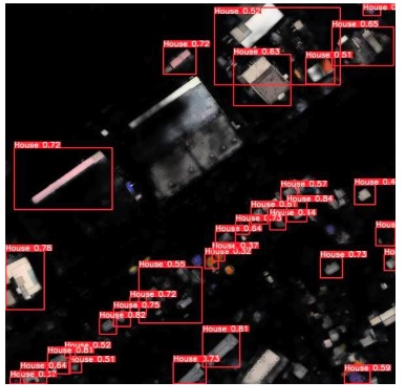
Эффекты примата «влияния цвета»

- Идентичные здания классифицируются по-разному.
- В другом примере несколько зданий объединены в один объект.

Нейросеть считает, что правильный дом – серый и некрасивый ☺

Ложное срабатывание



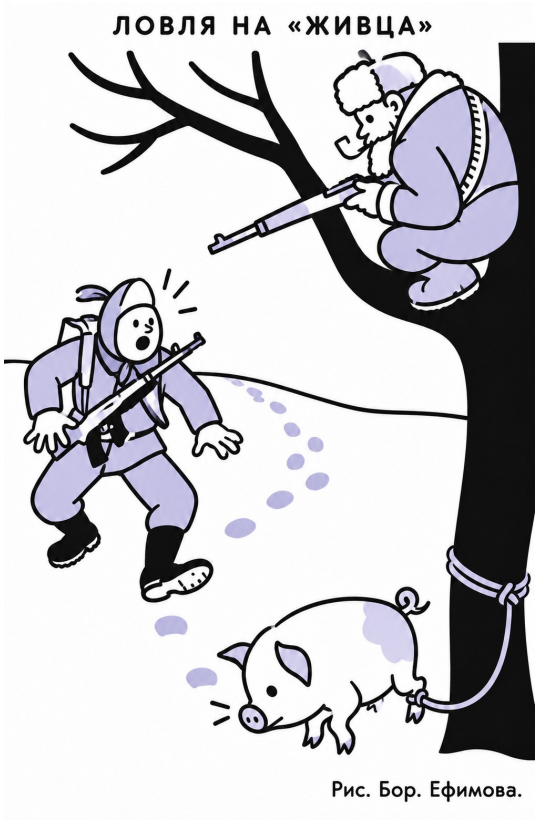


Группировка таунхаусов в одно здание





Как доверять ИИ в виде «черного ящика»



Почему модель ИИ теряет работоспособность:

- Допустимые вероятностные ошибки алгоритмов машинного обучения.
- Деградация алгоритмов в процессе самообучения
- Отсутствие качественного контроля данных, «мусорные» входные данные.
- Влияние внешних факторов (нестационарные эффекты, дрифт концепций).
- Злая воля (состязательные примеры, закладки и пр.).

«Ловля на живца»: генерация синтетических датасетов для генерации на их основе результатов модели ИИ с последующей проверкой качества.

Важно: нужен не только вход, но и выход.

Выводы (1/2)

- Перспективные методы ИИ направлены на имитацию когнитивной деятельности человека при решении разнообразных задач, включая автоматический дизайн физических объектов, автоматическое машинное обучение, работу с частично размеченными и малыми данными, интерпретируемую обработку данных и пр.

- Генеративный ИИ имитирует свойство креативности человека за счет разнообразия вариантов, который он может предложить. При этом чем больше параметров у генеративной модели, тем лучше результат.

- Генеративный интеллект использует случайные числа, и потому его ответы на один и тот же вопрос могут отличаться. При этом оценить качество своей работы (и достоверность ответа) – он не может.

- Автоматическое машинное обучение позволяет имитировать креативную деятельность датасайнтиста по созданию модели ИИ на данных. Оно может оценивать качество работы по тестовой выборке, и уже работает не хуже (и гораздо быстрее), чем опытный специалист

- Генеративный дизайн – это автоматическое проектирование объектов реального мира с помощью ИИ. В отличие от общего генеративного ИИ, генеративный дизайн выдает результаты, удовлетворяющие априорным требованиям. Но если требования не обозначены – делает, что считает нужным

Выводы (2/2)

- Чем более серьезные задачи решает ИИ и более сложные модели использует, тем сложнее интерпретировать результат его работы. Но для этого существуют методы объяснимого (explainable ИИ), которые позволяют оценить механизмы работы нейросетей в реальных условиях

- Если система ИИ представлена в форме «черного ящика», то оценить ее работу можно только экспериментальным путем: создав синтетические датасеты и оценив соответствие входных и выходных данных реальным ожиданиям потребителя

- На основе входных и выходных данных «черного ящика» может быть выполнен реинжиниринг ИИ, т.е. построена т.н. суррогатная модель, грубо описывающая принципы работы исходной системы. На основе реинжиниринга можно судить, соответствует ли данный ИИ априорным требованиям.

- Заказчики систем ИИ чаще всего грешат неоправданными ожиданиями от возможностей систем ИИ («справится со всем»), ретроградным мышлением и излишним доверием генеративным методам ИИ

- Разработчики систем ИИ чаще всего грешат необоснованным выбором моделей данных и математического аппарата, неумением корректно оценивать и сравнивать качество моделей, а также неспособностью определить границы применимости своего решения.